Отчёт по лабораторной работе №7

RAG: как нарезка документов влияет на поиск

AI Agents for Enterprise Processes Automation · Неделя 7

Имя и фамилия: Манасова Гулум **Группа:** Matdais23

1. Цель и условия

Цель: проверить на практике, как размер чанков влияет на качество поиска в RAG. База знаний — вымышленная компания ОсОО «АлаТех Солюшнс»: 532 документа (12 положений, 320 тикетов HelpDesk, 140 приказов, 60 FAQ) и 10 тестовых вопросов. Эмбеддинги — paraphrase-multilingual-MiniLM-L12-v2, хранилище — ChromaDB, нарезка — RecursiveCharacterTextSplitter, в контекст берутся top-5 чанков, ответы генерирует openai/gpt-oss-120b (Groq, temperature = 0).

2. Таблица 1. Результаты эксперимента

chunk_size	overlap	Чанков	Hit@1	Hit@5	MRR
200	30	1320	0,5	0,6	0,533
500	**75**	**697**	**0,5**	**0,8**	**0,592**
1000	150	629	0,3	0,5	0,353

Лучшая конфигурация по MRR — **500 / 75**. Ей же принадлежит максимальный Hit@5: нужный чанк попал в top-5 для 8 вопросов из 10 (не найдены q03 и q05).

3. Что нашёл поиск: q03 и q09 (шаг 6)

Вопрос, конфигурация	Что в top-5	Нужный чанк
q03, 200/30	пять приказов «О графике отпусков» (ORD-103, 031, 055, 023, 111), dist 0,42–0,43	не найден
q03, 500/75	шумовые фразы из POL-HR-002, POL-ADM-001/002, POL-HR-004 и тикет HD-11624, dist 0,41–0,47	не найден

Вопрос, конфигурация	Что в top-5	Нужный чанк
q03, 1000/150	пять тикетов «Вопрос по отпуску» (HD-11624, 12114, 10854, 10224, 10784), dist 0,469–0,471	не найден
q09, 200/30	пять приказов «О командировании» (ORD-068, 076, 116, 124, 028), dist 0,22–0,25	не найден
q09, 500/75	ORD-068, ORD-108, **ORD-087**, ORD-116, ORD-092	**3-е место** (dist 0,324)
q09, 1000/150	тот же результат, что при 500/75	**3-е место**

q03 («Суточные в Алматы»). Ни одна конфигурация не нашла POL-FIN-001. Причины: (1) в вопросе «Алматы», а в положении «Казахстан и Узбекистан», небольшая модель MiniLM не связала город со страной; (2) около 87% текста положений — типовые «заполнители» (оценка по коду генератора), поэтому чанк с суточными размыт общим текстом; (3) расстояния до всех пяти результатов почти одинаковы, уверенного лидера нет. Модель по смыслу уходит в «отпуск/командировки» и не опирается на слово «суточные».

q09 («Приказ №87-к»). При 500 и 1000 символов результаты совпадают, потому что приказ (в среднем около 290 символов) целиком помещается в один чанк. При 200 символов приказ режется на два чанка, и ORD-087 не попадает даже в top-5. Эмбеддинги плохо различают номера: в top-5 одни и те же шаблонные приказы с другими номерами, а нужный стоит только на 3-м месте.

4. Таблица 2. Оценка ответов (шаг 7, конфигурация 500/75)

Вопрос	Найден ли чанк	Оценка	Комментарий
q01	да	0,5	24 дня верно, но нет +4 дней при стаже свыше 3 лет
q02	да	1	Верно
q03	нет	0	Ошибка поиска; модель честно ответила «нет информации»
q04	да	0,5	«Не более 2 дней» верно, нет условия «после испытательного срока»

Вопрос	Найден ли чанк	Оценка	Комментарий
q05	нет	0	Политика паролей вытеснена тикетами «Сброс пароля» (HD-11827)
q06	да	1	Верно
q07	да	1	Верно
q08	да	1	60 000 сом в год: ответ на заданный вопрос верен
q09	да	1	Верно: Садыков Б. А. (ORD-087)
q10	да	1	До 5 000 сом без подтверждения: верно по существу вопроса
Итого	—	**7 / 10**	Точность 70%

Автоэвристика (rapidfuzz) дала 6,5 / 10. Я проверил все 10 строк вручную: q08 и q10 ответ полностью закрывает вопрос (дополнение из эталона не спрашивали), поэтому оценка выше.

5. Ответы на вопросы

1. Какая конфигурация лучшая по MRR и почему? 500/75: MRR 0,592 против 0,533 (200/30) и 0,353 (1000/150), Hit@5 равен 0,8 против 0,6 и 0,5. Слишком мелкие чанки (1320 штук) разрывают факт и порождают много чанков, состоящих только из общего текста, которые забивают выдачу (q09 при 200 символах). Слишком крупные (1000 символов) объединяют несколько тем в одном векторе, он перестаёт точно совпадать с вопросом, и Hit@1 падает до 0,3. Чанков при 1000/150 всего 629, потому что тикеты, приказы и FAQ короче 1000 символов и не режутся, режутся только 12 положений. Оговорка: вопросов всего 10 (один вопрос = 0,1 к Hit), поэтому разница 500/75 и 200/30 небольшая, а вывод о том, что 1000/150 хуже, надёжнее.

2. Какую точность дала лучшая конфигурация? Совпадают ли ошибки с колонкой «найден ли чанк»? Точность 7 / 10 (70%). Оба нулевых ответа (q03, q05) совпадают с «нет» в колонке чанка: без нужного контекста модель ответить не могла и при этом не стала выдумывать. Обратное неверно: из 8 вопросов с «да» полностью верны 6, а q01 и q04 только частично. Метрика проверяет наличие одного фрагмента (gold snippet), а в этих вопросах ответ состоит из двух частей (основной срок и условие), и модель дала только первую.

3. **Разбор ошибки: q03.** Это ошибка **поиска**, а не модели: нужный документ не найден ни при одном размере чанка (см. раздел 3), а модель при ненужном контексте правильно ответила «В документах нет информации». Что улучшить: (1) расширить запрос («Алматы» → «Казахстан»); (2) гибридный поиск BM25 + эмбеддинги, чтобы точное слово «суточные» имело вес; (3) фильтр по метаданным type = policy для вопросов о правилах; (4) нарезка по заголовкам разделов (##) и удаление шаблонных фраз; (5) более сильная многоязычная модель эмбеддингов и reranker; (6) увеличить k до 10. Для q05 причина та же: тикеты «Сброс пароля» вытесняют положение.

6. Замечания к ноутбуку

В шаге 8 строка `best_row = results.iloc[0]` брала первую строку таблицы вместо лучшей, исправлено на выбор по максимальному MRR. Переменная `BEST` теперь определяется автоматически. Добавлена ячейка, которая выводит top-5 для q03 и q09 во всех трёх конфигурациях.

7. Использование ИИ

ИИ-ассистент Claude (Anthropic) использовался для проверки кода ноутбука, поиска ошибок и подготовки текста отчёта. Ноутбук запускался мной в Google Colab, все цифры взяты из вывода ячеек; LLM в эксперименте — openai/gpt-oss-120b через Groq.