Отчёт по лабораторной работе №7

RAG: как нарезка документов влияет на поиск

AI Agents for Enterprise Processes Automation · Неделя 7

Имя и фамилия: Манасова Гулум · **Группа:** Matdais23

1. Цель и условия

Цель: проверить на практике, как размер чанков влияет на качество поиска в RAG. База знаний — вымышленная компания ОсОО «АлаТех Солюшнс»: 532 документа (12 положений, 320 тикетов HelpDesk, 140 приказов, 60 FAQ) и 10 тестовых вопросов. Эмбеддинги — paraphrase-multilingual-MiniLM-L12-v2, хранилище — ChromaDB, нарезка — RecursiveCharacterTextSplitter, в контекст берутся top-5 чанков. Ответы генерирует openai/gpt-oss-120b (Groq, temperature = 0): модель из шаблона ноутбука заменена на поддерживаемую Groq, как допускает задание.

2. Таблица 1. Результаты эксперимента (шаг 5)

chunk_size	overlap	Чанков	Hit@1	Hit@5	MRR
200	30	1320	0,5	0,6	0,533
500	**75**	**697**	**0,5**	**0,8**	**0,592**
1000	150	629	0,3	0,5	0,353
500 (бонус)	50	696	0,4	0,8	0,525

Лучшая конфигурация по MRR — **500/75**. Ей же принадлежит максимальный Hit@5: нужный чанк попал в top-5 для 8 вопросов из 10 (не найдены q03 и q05).

Бонус: своя конфигурация 500/50. Размер чанка тот же, overlap уменьшен с 15% до 10%. Число чанков почти не изменилось (696 против 697): режутся в основном положения, остальные документы короче 500 символов. Hit@5 прежний (0,8), но Hit@1 упал с 0,5 до 0,4, а MRR — с 0,592 до 0,525: один вопрос потерял первое место, вероятно из-за сдвига границ чанков. Вывод: overlap влияет слабее, чем chunk_size, но на границах чанков он важен. Оговорка: вопросов всего 10, один вопрос меняет Hit на 0,1.

3. Что нашёл поиск: q03 и q09 (шаг 6)

Вопрос, конфигурация	Что в top-5	Нужный чанк
q03, 200/30	пять приказов «О графике отпусков» (ORD-103, 031, 055, 023, 111), dist 0,42–0,43	не найден
q03, 500/75	шумовые фразы из POL-HR-002, POL-ADM-001/002, POL-HR-004 и тикет HD-11624, dist 0,41–0,47	не найден
q03, 1000/150	пять тикетов «Вопрос по отпуску» (HD-11624, 12114, 10854, 10224, 10784), dist 0,469–0,471	не найден
q09, 200/30	пять приказов «О командировании» (ORD-068, 076, 116, 124, 028), dist 0,22–0,25	не найден
q09, 500/75	ORD-068, ORD-108, **ORD-087**, ORD-116, ORD-092	3-е место (dist 0,324)
q09, 1000/150	тот же результат, что при 500/75	3-е место

q03 («Суточные в Алматы»). Ни одна конфигурация не нашла POL-FIN-001. Причины: (1) в вопросе «Алматы», а в положении «Казахстан и Узбекистан» — небольшая модель MiniLM не связала город со страной; (2) около 90% текста положений — типовые «заполнители» (оценка по коду генератора), поэтому чанк с суточными размыт общим текстом; (3) расстояния до всех пяти результатов почти одинаковы, уверенного лидера нет.

q09 («Приказ №87-к»). При 500 и 1000 символов результаты совпадают: приказ (в среднем 293 символа) целиком помещается в один чанк. При 200 символах он режется на два чанка, и ORD-087 не попадает даже в top-5. Эмбеддинги плохо различают номера: в выдаче шаблонные приказы с другими номерами, а нужный стоит только на 3-м месте.

4. Таблица 2. Оценка ответов (шаг 7, конфигурация 500/75)

Вопрос	Найден ли чанк	Оценка	Комментарий
q01	да	0,5	«24 дня» верно, источник — актуальное POL-HR-001, а не утратившее силу POL-HR-000; нет +4 дней при стаже свыше 3 лет
q02	да	1	Верно: за 14 дней; одна часть отпуска не менее 14 дней
q03	нет	0	Ошибка поиска; модель честно ответила «нет информации»
q04	да	0,5	«Не более 2 дней» верно; нет условия «после испытательного срока»
q05	нет	0	Политика паролей вытеснена тикетами «Сброс пароля» (HD-11827); «нет информации»
q06	да	1	Верно: 1 час, security@alatech.kg, 777
q07	да	1	Верно: 5 рабочих дней
q08	да	1	60 000 сом в год — полный ответ на заданный вопрос (перенос остатка не спрашивали)
q09	да	1	Верно: Садыков Б. А. (ORD-087)
q10	да	1	До 5 000 сом — верно по существу вопроса
Итого	—	**7 / 10**	**Точность 70%**

5. Ответы на вопросы

1. Какая конфигурация лучшая по MRR и почему? 500/75: MRR 0,592 против 0,533 (200/30) и 0,353 (1000/150), Hit@5 равен 0,8 против 0,6 и 0,5. Слишком мелкие чанки (1320 штук) разрывают факт и дают много почти одинаковых фрагментов, например заголовки шаблонных приказов, по которым нельзя различить номер (q09 при 200 символах). Слишком крупные (1000 символов) объединяют несколько тем в одном векторе, он хуже совпадает с вопросом, и Hit@1 падает до 0,3. Чанков при 1000/150 всего 629, потому что тикеты, приказы и

FAQ короче 1000 символов и не режутся — режутся только 12 положений. Оговорка: вопросов всего 10, поэтому разница между 500/75 и 200/30 небольшая, а вывод о том, что 1000/150 хуже, надёжнее.

2. **Какую точность дала лучшая конфигурация? Совпадают ли ошибки с колонкой «найден ли чанк»?** Точность 7 / 10 (70%). Оба нулевых ответа (q03, q05) совпадают с «нет» в колонке чанка: без нужного контекста модель ответить не могла и при этом не стала выдумывать. Обратное неверно: из 8 вопросов с «да» полностью верны 6, а q01 и q04 — только частично. Метрика проверяет наличие одного фрагмента (gold snippet), а в этих вопросах ответ состоит из двух частей (основной срок и условие), и модель дала только первую.

3. **Разбор ошибки: q03.** Это ошибка поиска, а не модели: нужный документ не найден ни при одном размере чанка (раздел 3), а при ненужном контексте модель правильно ответила «В документах нет информации». Что улучшить: (1) расширить запрос («Алматы» → «Казахстан»); (2) гибридный поиск BM25 + эмбеддинги, чтобы точное слово «суточные» имело вес; (3) фильтр по метаданным type = policy для вопросов о правилах; (4) нарезка по заголовкам разделов (##) и удаление шаблонных фраз; (5) более сильная многоязычная модель эмбеддингов и reranker; (6) увеличить k до 10. Для q05 причина та же: тикеты «Сброс пароля» вытесняют положение.

6. Использование ИИ

ИИ-ассистент Claude (Anthropic) использовался для объяснения кода ноутбука, проверки отчёта на соответствие заданию и подготовки текста отчёта. Ноутбук запускался мной в Google Colab, все цифры взяты из вывода ячеек; LLM в эксперименте — openai/gpt-oss-120b через Groq.